



أكاديمية
AL FIHRIYA
الفهرية ACADEMY

حصص في التعلم الآلي


الحصة الرابعة



زكرياء



رضوان



سكينة



أحمد

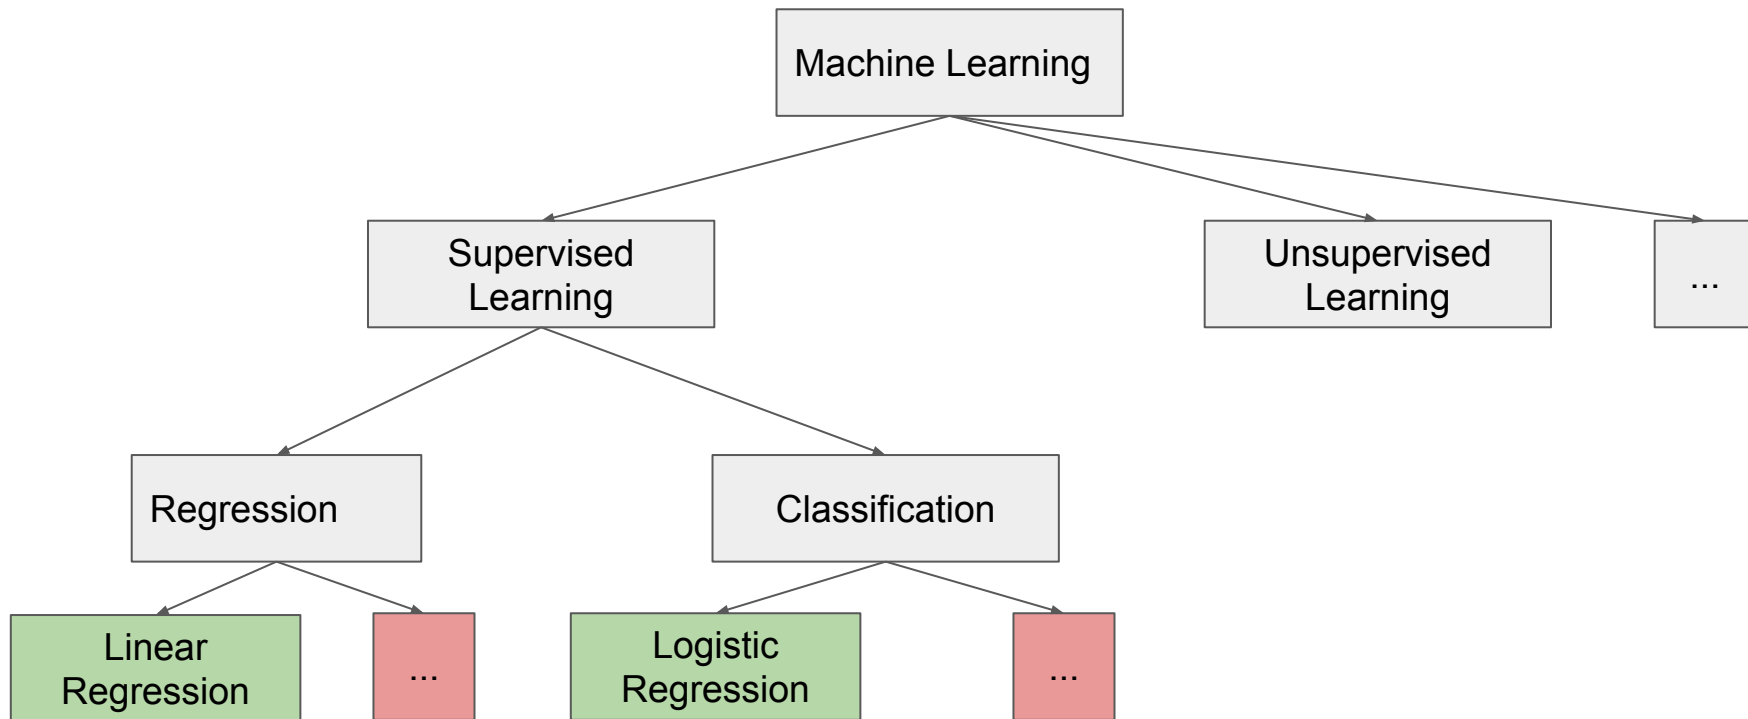
فهرس الحصة 4: Over/Under-fitting and Regularization

1. ملخص
2. الهدف العام من التعلم الآلي
3. Overfitting
4. Underfitting
5. حلول لهذه المشاكل

مصطلحات

- **Prediction**: تنبؤ
- **target/label**: ما نحاول تنبؤه.
- **features/predictors**: المعطيات و البيانات (données) التي نستعملها للتنبؤ.
- **regression**: إنحدار، أو تنبؤ رقم ما.
- **classification**: تصنيف، أو تنبؤ مجموعة ما تنتمي إليها بعض المعطيات.

أنواع مشاكل التعلم الآلي



الهدف ديال Supervised Learning

- Supervised Learning هو فاش كانبغيو نقادو نموذج باش يتنبأ لينا بالقيمة ديال الهدف
 - مثال: الثمن ديال دار (الإنحدار)، واش إيميل سپام او لا لا (تصنيف)
- النموذج ديالنا هو واحد الدالة f و قيمة التنبؤ هي $f(x)$ و القيمة الحقيقية هي y
 - مثلاً إلا كان النموذج ديالنا هو الإنحدار الخطي Linear Regression فالدالة f هي:

$$f(x) = \beta_0 + \beta x$$

- باش نلقاو هاد القيم (β, β_0) ، كانحلو هاد optimization:

$$\text{Minimize } \sum_i \text{erreur}(f(x_i), y_i))$$

كيفاش كانلقاو les parametres ديال النموذج ديالنا:

$$\text{Minimize } \sum_i \text{erreur}(f(x_i), y_i))$$

- هاد الخطأ ممكن نعبرو عليه بأشكال مختلفة، طريقة المربعات الصغرى هي اللي معروفة بزاف
 - المربعات الصغرى

$$\text{erreur}(f(x_i), y_i) = (f(x_i) - y_i)^2$$

- كيفما قلنا في الإنحدار الخطي كاتولي هي:

$$\text{Minimize}_{\beta_0, \beta} \sum_i (y_i - \beta_0 - \beta x_i)^2$$


الإنحدار الخطي Linear Regression

- الإنحدار الخطي تيتستعمل في مشاكل تنبؤ كمية أو رقم ما.
- تنستعملوا هذا النموذج فاش تتكون علاقة خطية بين المعطيات ديالنا (features) و ما يراود تنبؤة (target)
-

$$\boxed{y_i} = \beta_0 + \boxed{\beta_1} \boxed{x_{1i}} + \beta_2 x_{2i} + \dots + \beta_n \boxed{x_{ni}}$$


Target / Label Coefficient of feature #1 Feature #1 Feature #n

مثال للإنحدار الخطي



$$y_i = \beta_0 + \beta_1 x_i$$

مثال للإنحدار الخطي



الانحدار اللوجستي

- كانستعملو الانحدار اللوجستي لمشكل التصنيف
 - ملحوظة: الانحدار اللوجستي حتى هو نموذج خطي بحال الانحدار الخطي غير هو كايستعمل فمشاكل التصنيف




$$P(y = red|x) = \frac{1}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2}}$$


الإحتمال ديال أن x
تكون حمرا

نأخذو واحد المثال

- أش بان ليكوم كيدايرة العلاقة بين x و y ؟




نأخذو واحد المثال



- نديرو الإنحدار الخطي (Linear Regression) و نلقاو **line of best fit** ديالنا
- ولكن هاذ النموذج باقي فيه أخطاء
- بغينا نلقاو النموذج المثالي

نقادو نموذج مثالي




- بلاصت مانستعملو غير واحد x
- نزيدو polynomials دياولنا

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_2 x^3 + \beta_3 x^4 + \beta_4 x^5 + \beta_6 x^6 + \beta_7 x^7$$

- دبا هاد النموذج مثالي مافيه حتى خطأ

نشوفو كيفاش كاي تقارنو هاد جوج نماذج فاش كاتكون observation جديدة :




- حنا كانقادو النموذج ديانا
باش يقدر يعرف القيمة
ديال البيانات اللي عمرو
ماشاف
- النموذج الأزرق كايدير
خطأ صغير
- بينما النموذج الأخضر
كايدير خطأ كبير

Generalization

- Generalization هو واحد المبدأ اللي كايقول لنا كيفاش هاد النموذج ديالنا كاي تعامل مع البيانات اللي عمرو ماشاف
- أحسن نموذج هو `kaygeneralize` اللي مزيان

Overfitting فلا إنحدار الخطي:





- هاذ المثال اللي درنا كايبين **overfitting**
- Overfitting هو فاش كاتعطي للنموذج ديالك بزاف ديال **(power (complexity** اللي كاتمكنو يعقل على البيانات أكثر من القياس



$$\sum_i \text{erreur}(f(x_i), y_i) \approx 0$$

- مثلاً فهاذ المثال النموذج حفظ البيانات كاملين

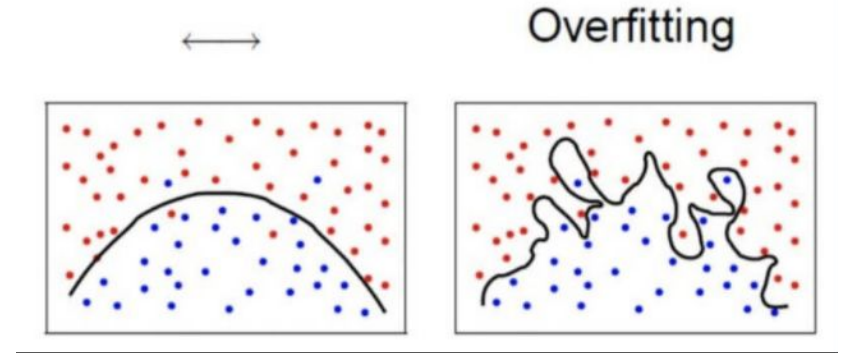
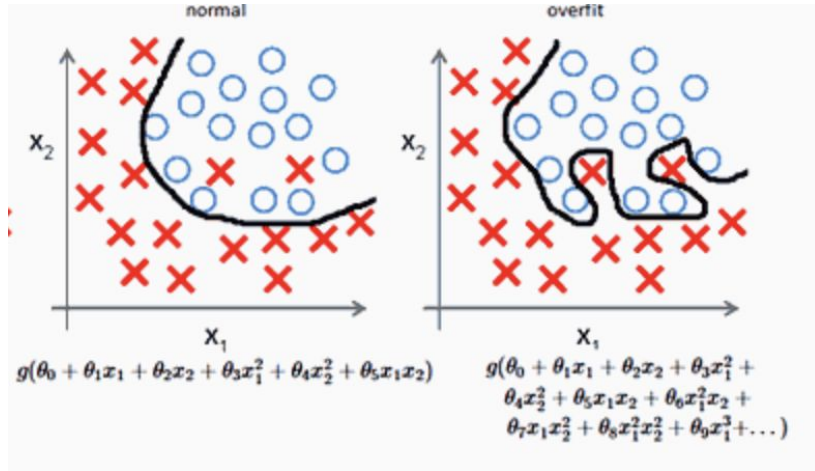
Overfitting كايتمسمى كذلك Variance problem

- إلا بديتو كاتقراو، أتسمعو بزاف على bias vs variance tradeoff
- Overfitting هو المشكل ديال Variance
- علاش سميتو variance problem؟
 - إلا بدلتى البيانات ديالك بشوية، ديالك غايتبدلو بزاف
 - زدنا نقطة حمرا و تبدلات الدالة كاملة






Overfitting في التصنيف



Underfitting

- Underfitting هو العكس ديال ال Overfitting
- النموذج ما عندوش **القدرة Capacity** الكافية باش يلقى العلاقة الخفية فالبيانات
- مثال:




Underfitting

- Underfitting هو العكس ديال ال Overfitting
- النموذج ما عندوش **القدرة Capacity** الكافية باش يلقى العلاقة الخفية فالبيانات
- مثال:


- ايلّا ختارينّا انحدار خطي **Linear Regression** ب feature وحيدة

$$y_i = \beta_0 + \beta x_i$$



Underfitting

- ال Underfitting هو العكس ديال ال Overfitting
- النموذج ما عندوش **القدرة Capacity** الكافية باش يلقى العلاقة الخفية فالبيانات
- مثال:



- ايل اختاريننا انحدار خطي **Linear Regression** ب feature وحيدة



$$y_i = \beta_0 + \beta x_i$$

- النموذج اللي موالم حسن هو انحدار خطي حدودي من الدرجة الثانية

Linear regression with polynomial 2nd degree

كيفما درنا وحلة

- ايل عطينا للنموذج بزاف ديال القوة ← Overfitting
- ايل عطينا للنموذج شوية ديال القوة ← Underfitting



كيفاش كاتحكمو فالقوة ديال الموديل ديالنا؟

● Features

- ختار Features اللي تقدر تبين ان كاينة علاقة سببية Causality بينهم و بين ال Target ديالك
- مزيان يكونو عندك بزاف ديال Features
- Interaction between features
- Nonlinear transformation to features

● خطي VS لا خطي

- Linear regression
 - Decision Trees
 - Neural Networks
 - SVM
- Hyperparameter tuning {

● Data

- Number of observations عدد القياسات
- class Imbalance

● Regularization

شناهيا Regularization ؟

- Regularization كاتعاوننا نتحكمو فال Complexity ديال النموذج ديانا
- كانقدرو نستعملو عا فبزاف ديال التقنيات
- تذكير:

$$\text{Minimize } \sum_i \text{erreur}(f(x_i), y_i))$$

- Regularization كاتطبق واحد العقاب Penalty على ال Complexity ديال النموذج ديانا

$$\text{Minimize } \sum_i \text{erreur}(f(x_i), y_i) + \lambda R(f)$$

Lambda

Regularizer

كيفاش Regularization كاتحکم فال Complexity؟

$$\text{Minimize } \sum_i \text{erreur}(f(x_i), y_i) + \lambda R(f)$$

فاش كانزیدو
ال Complexity ديال
الدالة f



هاد الخطأ كايهبط

هاد Penalty كاتطلع

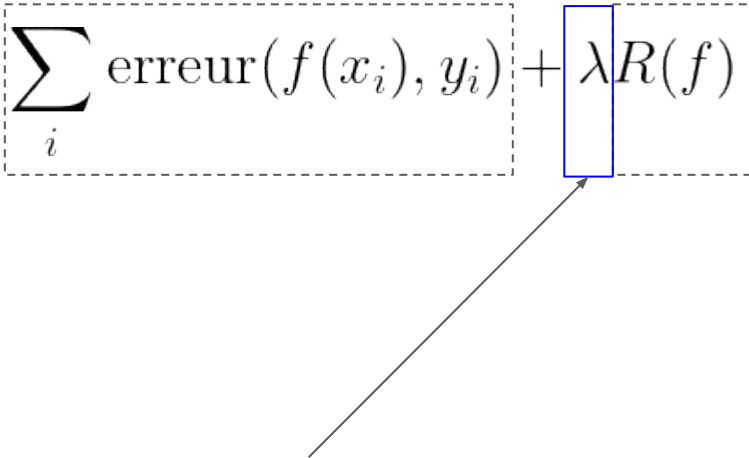


ال Optimization كاتخلينا نلقاو النموذج اللي كايوازن ما بين:

- Fit
- Complexity

Lambda

Minimize $\sum_i \text{erreur}(f(x_i), y_i) + \lambda R(f)$



Lambda كاتخلينا نتحكمو بالشدة ديال
Regularization ال

أنواع الـ Regularization: مثال الانحدار الخطي Linear Regression

- Ridge regression

$$\text{Minimize } \sum_i \boxed{\text{erreur}(f(x_i), y_i)} + \lambda \boxed{R(f)}$$

$$\text{Minimize } \sum_i \boxed{(y_i - \beta^T x_i)^2} + \lambda \boxed{\|\beta\|_2^2}$$

$$\|\beta\|_2^2 = \sum \beta_j^2$$


أنواع الRegularization: مثال الانحدار الخطي Linear Regression

- Ridge regression $f(x_i) = \beta^T x_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_m x_{im}$

$$\text{Minimize } \sum_i \boxed{\text{erreur}(f(x_i), y_i)} + \lambda R(f)$$

$$\text{Minimize } \sum_i \boxed{(y_i - \beta^T x_i)^2} + \lambda \|\beta\|_2^2$$

$$\|\beta\|_2^2 = \sum \beta_j^2$$



أنواع الـ Regularization: مثال الانحدار الخطي Linear Regression

- Lasso regression $f(x_i) = \beta^T x_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_m x_{im}$

$$\text{Minimize } \sum_i \boxed{\text{erreur}(f(x_i), y_i)} + \lambda \boxed{R(f)}$$

$$\text{Minimize } \sum_i \boxed{(y_i - \beta^T x_i)^2} + \lambda \boxed{\|\beta\|_1^2}$$

$$\|\beta\|_1^2 = \sum_j |\beta_j|$$

Lambda

Minimize $\sum_i \text{erreur}(f(x_i), y_i) + \lambda R(f)$

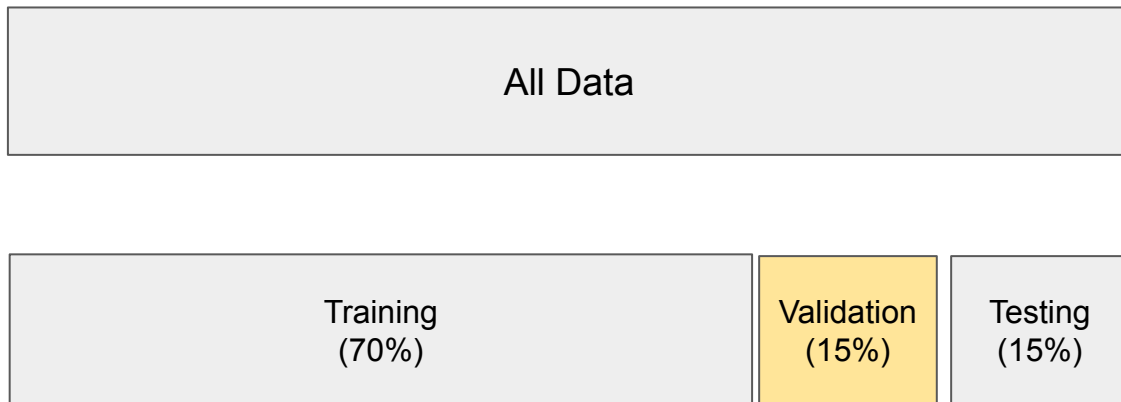
Lambda كاتخلينا نتحكمو بالشدة
Regularization ديال

:Lambda

- ايل ختاريننا Lambda **طالعة** بزاف، النموذج ديانا كايكون بسيط بزاف (**underfitting**)
- ايل ختاريننا Lambda **ضعيفة** بزاف، النموذج ديانا كايكون معقد بزاف (**overfitting**)

کیفیت کا اختارو Lambda

- کانستعملو Validation set



كيفاش كاختارو Lambda

- كنجربو بزاف ديال القيم ديال Lambda و كاناخدو القيمة اللي كاتوصلنا لأقل خطأ ف Validation set

Step 1:

- ختار واحد القيمة ديال Lambda

Example

$$\lambda = 1.5$$

Step 2:

- Solve the optimization problem

$$\text{Minimize } \sum_i (y_i - \beta^T x_i)^2 + 1.5 \|\beta\|_2^2$$

Step 3:

- N7essbou l'erreur f validation set

$$\text{Minimize } \sum_i (y_i - \beta^T x_i)^2$$

Step 4:


- Kan9eydou les valeurs:
 - Lambda
 - Validation error
 - parameters

repeat

كيفاش كانختارو Lambda

Lambda	Validation Error
0.1	213
0.2	190
0.5	180
1	140
...	...
...	...
3.5	156
4.7	161
6	173
9	184

Validation
Error



احسن Lambda لقينا

خلاصة الدرس

- الهدف ديال Supervised learning
- Overfitting / Underfitting
- التقنيات باش تحكم فال Complexity ديال النموذج ديالك
- Regularization